1. Customer Service Ticket Triage & RAG Copilot

Sistem pengelompokan tiket layanan pelanggan otomatis berbasis Multi-Task IndoBERT, LoRA, dan Retrieval-Augmented Generation

Proyek ini berangkat dari persoalan nyata pada operasional layanan dukungan teknis perangkat lunak skala korporat. Setiap harinya, tim layanan pelanggan menerima ribuan pesan keluhan berbahasa Indonesia yang gaya penulisannya sangat beragam—mulai dari bahasa formal, bahasa gaul (*slang*), singkatan percakapan, salah ketik (*typo*), hingga satu tiket yang memuat beberapa masalah sekaligus (*multi-issue tickets*). Ketika diuji menggunakan pendekatan klasifikasi konvensional berbasis kata kunci seperti TF-IDF dan LightGBM, model kesulitan memahami konteks kalimat dan hanya mampu mengenali 53,57% tiket berstatus darurat (*Critical*). Akibatnya, gangguan besar seperti mesin kasir (POS) mati atau portal akademik yang lumpuh berisiko terlambat ditangani.

Untuk menyelesaikan masalah tersebut tanpa membutuhkan komputasi pelatihan yang mahal, saya merancang arsitektur pembelajaran multi-tugas (*multi-task learning*) menggunakan model bahasa *indobenchmark/indobert-base-p1* yang dipadukan dengan teknik *Low-Rank Adaptation* (PEFT/LoRA). Hasil klasifikasi ini kemudian dihubungkan dengan sistem pencarian dokumen SOP internal (*Retrieval-Augmented Generation* / RAG) agar staf layanan pelanggan langsung mendapatkan draf solusi teknis yang relevan.

- **Pembagian Data Bebas Kebocoran & Sanitasi Privasi:** Dataset berisi 1.200 tiket keluhan dibagi menggunakan metode *GroupShuffleSplit* berdasarkan ID pengguna (`user_id`) menjadi 840 tiket latih (168 pengguna), 180 tiket validasi (36 pengguna), dan 180 tiket uji (36 pengguna). Cara ini memastikan tidak ada pengguna yang sama di data latih dan data uji sehingga model tidak sekadar menghafal kebiasaan ketik seseorang. Sebelum diproses, informasi pribadi seperti nomor telepon, alamat surel, dan ID transaksi disamarkan otomatis ke kolom `sanitized_message` menggunakan *masker* berbasis *regex* deterministik dan aturan kontekstual (bukan model NER terlatih), dengan Exact-Match F1 1.0000 pada data sintetis.
- **Adaptasi LoRA & Dua Kepala Klasifikasi Paralel:** Bobot utama IndoBERT dibekukan dan hanya disisipkan matriks adaptasi LoRA ($r = 16$, lora_alpha = 32, dropout = 0.10) pada lapisan atensi *query*, *key*, *value*, dan *dense*. Strategi ini membuat model hanya perlu melatih 3.078.664 parameter dari total 127.520.008 parameter (2,4143%). Vektor representasi kalimat (768 dimensi) diteruskan ke dua jalur prediksi sekaligus ($768 \to 256 \to 4$): (1) *CategoryHead* untuk membedakan 4 jenis layanan (*Hardware_POS*, *Billing_Payment*, *Academic_Portal*, *Warranty_Claim*) dengan *Cross-Entropy Loss* (*label smoothing* 0.05); serta (2) *UrgencyHead* untuk memprediksi 4 tingkat kedaruratan (*Low*, *Medium*, *High*, *Critical*) menggunakan *Multi-Class Focal Loss* ($\gamma = 2.0$) berbobot terbalik (α_t) agar model lebih peka terhadap tiket kritis yang jumlahnya sedikit.
- **Kalibrasi Probabilitas Out-of-Fold (OOF):** Agar tingkat keyakinan model lebih terukur saat digunakan di lingkungan kerja nyata, nilai keluaran logit dikalibrasi ulang menggunakan *Temperature Scaling* ($T = 0.60$) pada data validasi. Selain itu, batas ambang keputusan khusus kelas *Critical* diatur pada $\theta^*_{\text{crit}} = 0.495$ untuk memaksimalkan skor $F_{\beta=1.5}$ validasi (mencapai 0.9848), sehingga tidak ada satu pun tiket darurat pada data uji yang terlewat.

Metrik Evaluasi (Data Uji = 180 Tiket)	Baseline (TF-IDF+LGBM)	IndoBERT + LoRA (Argmax)	IndoBERT + LoRA (OOF Calibrated)	Selisih vs Baseline (poin absolut)
Category Macro-F1 (4 Kategori Layanan)	0.7713	0.9818	**0.9818**	+0.2105
Urgency Macro-F1 (4 Tingkat Kedaruratan)	0.6259	0.9644	**0.9644**	+0.3385
Critical Ticket Recall (Deteksi Insiden Darurat)	0.5357	1.0000	**1.0000**	+0.4643
Critical Ticket PR-AUC / F1-Score	0.6745 / 0.6667	1.0000 / 0.9825	**1.0000 / 0.9825**	+0.3255 / +0.3158
Critical Ticket Precision	0.8824	0.9655	**0.9655**	+0.0831

2. KlaimKilat AI — Omnichannel Reimbursement & Audit Agent

Agen audit klaim reimbursement karyawan berbasis LangGraph stateful, Hybrid RAG (pgvector + Full-Text Search), dan Human-in-the-Loop

Pada operasional keuangan perusahaan multi-cabang, proses verifikasi klaim reimbursement (struk makan, transportasi, akomodasi, ATK) masih dikerjakan manual: staf finance harus mencocokkan tiap struk dengan pasal SOP Keuangan, memeriksa sisa kuota bulanan karyawan, dan mendeteksi klaim ganda atau item terlarang (rokok, alkohol, kebutuhan pribadi). Proses ini lambat, tidak konsisten antar-penilai, dan rawan lolosnya klaim yang melanggar aturan. Saya merancang **KlaimKilat AI**, sebuah agen otomatis yang menerima foto struk dari tiga kanal (Portal Web Scanner, Telegram Bot, WhatsApp) lalu memutuskan *Auto-Approve*, *Auto-Reject*, atau *Escalate* ke Manajer Finance—dengan setiap keputusan ditambatkan (*grounded*) ke pasal SOP yang relevan agar tidak berhalusinasi.

- **Orkestrasi *Stateful* LangGraph & Human-in-the-Loop:** Alur kerja dibangun sebagai *StateGraph* LangGraph dengan *checkpointer* sehingga eksekusi dapat dibekukan dan dilanjutkan. Node berurutan: `ingest_and_dedup`

(deteksi struk ganda via *perceptual + content hash*), `vision_extraction` (ekstraksi item struk terstruktur; *confidence* $< 0{,}65$ meminta unggah ulang), `hybrid_policy_rag` (pencocokan pasal SOP), lalu `quota_and_audit` yang memanggil *tool* SQL (`get_employee_monthly_balance`, `check_receipt_date_validity`). Klaim $\leq$ Rp250.000 yang patuh di-*auto-approve*; klaim duplikat/kedaluwarsa (> 14 hari)/kuota habis/item terlarang di-*auto-reject*; klaim besar atau struk gabungan dibekukan dengan `interrupt()` dan dilanjutkan lewat `Command(resume=...)` setelah Manajer menekan tombol *inline keyboard*.

- **Hybrid RAG Penambat Kebijakan (pgvector + FTS + RRF):** Dokumen SOP Keuangan dipotong secara sadar-struktur (*table-aware*, breadcrumb `[Dokumen | Bab | Pasal]`) lalu diindeks ganda: pencarian vektor padat (pgvector, 1024-dim) dan pencarian teks penuh (*Full-Text Search* `tsvector`), yang digabung dengan *Reciprocal Rank Fusion* ($k = 60$). Model audit (`deepseek-chat`) memakai hasil retrieval beserta *guardrail* anti-*prompt injection* yang menjaga *False Auto-Approve Rate* tetap 0%. Seluruh pipeline disajikan sebagai layanan mikro FastAPI + Redis dengan telemetri produksi per-node (*latency*, token, estimasi biaya Rupiah).

Metode Retrieval Pasal SOP (40 Skenario Klaim)	**Recall@4** (Target $\geq 0{,}90$)	**MRR** (Target $\geq 0{,}82$)
Vector Search Saja (pgvector dense)	1,0000	1,0000
Keyword Search Saja (Full-Text Search)	1,0000	0,9583
Hybrid Search (RRF, $k = 60$)	**1,0000**	**1,0000**

3. TransitSentinel — Real-Time Cashless Transit Anomaly Detection & Settlement Audit Pipeline

Mesin deteksi anomali pembayaran transportasi publik multi-tingkat (Guardrail deterministik, PyTorch Residual VAE, dan Isolation Forest + LightGBM Stacking) berlatensi sub-25 ms

Pada operasional pembayaran transportasi publik skala besar (*Tap-on-Bus / TOB* dan gerbang putar *turnstile*), sistem transaksi nirsentuh (kartu prabayar perbankan dan ponsel *QRIS Tap NFC*) kerap mengalami anomali operasional akibat guncangan armada, fluktuasi sinyal seluler, pemrosesan luring (*store-and-forward offline*), maupun kecurangan (*fraud*). Permasalahan kritis mencakup tagihan ganda (*double-tap glitch* akibat keterlambatan bunyi *beep*), kecepatan mustahil akibat kloning kartu (*impossible travel clone*), penghindaran tarif (*pass-back / incomplete tap-out*), serta selisih setoran kas pada unggahan berkas *batch* depo luring. Saya merancang **TransitSentinel**, sebuah pipeline produksi terintegrasi yang mendeteksi dan mengotomasi remediasi anomali secara waktu nyata pada 120.000 transaksi transit menggunakan arsitektur hybrid 3-tier, router sensitif biaya, dan auditor rekonsiliasi kas berbasis statistik *robust*.

- **Rekayasa 28 Fitur Spasio-Temporal Kausal & Zero Temporal Leakage:** Dataset aliran 120.000 transaksi transit disimulasikan secara realistis melintasi 45 halte bus/stasiun dan 120 perangkat TOB. Seluruh data dibagi secara kronologis ketat (Hari 1–10 Data Latih 84.000 baris, Hari 11–12 Validasi 18.000 baris, Hari 13–14 Data Uji 18.000 baris) guna menjamin tidak ada kebocoran temporal (*zero temporal leakage*). Sistem mengekstrak 28 fitur kausal ($t' \leq t$) yang terbagi ke dalam empat keluarga: (1) kecepatan geodesik Haversine dan indikator kecepatan mustahil (> 120 km/jam); (2) frekuensi jendela geser kausal *double-tap* (15 detik hingga 24 jam), rasio *incomplete tap-out* 7 hari, dan hitungan *pass-back*; (3) telemetri kesehatan pembaca (*rolling latency z-score*, rasio *retry* 5 menit, dan penundaan sinkronisasi luring); serta (4) deviasi tarif koridor dan siklus waktu sinusoidal.
- **Mesin Hybrid 3-Tier, PyTorch Residual VAE, & Router Biaya Optimal ($\tau^* = 0.41$):** (1) **Tier 1 — Guardrail Deterministik (< 0.1 ms):** Memotong seketika anomali aturan keras seperti *double-tap* ≤ 8 detik (`AUTO_REFUND_DUPLICATE`) dan kloning kartu berkecepatan > 120 km/jam (`TEMP_FREEZE_TOKEN`); (2) **Tier 2 — PyTorch Residual Variational Autoencoder (VAE):** Dilatih murni pada data transaksi normal untuk mengenali pola anomali baru (*zero-day*) melalui lonjakan galat rekonstruksi gabungan MSE dan divergensi KL; (3) **Tier 3 — Isolation Forest + Calibrated LightGBM Stacking & TreeSHAP:** Menggabungkan probabilitas terkalibrasi dengan penjelasan atribusi TreeSHAP. Skor risiko dialirkan ke router sensitif-biaya (*cost-sensitive router*) pada ambang optimal $\tau^* = 0.41$ yang menghemat 98,0% biaya anomali (penghematan bersih Rp 13.975.000 pada data uji). Seluruh pipeline inferensi disajikan melalui FastAPI berlatensi p50 < 12 ms (p95 < 25 ms), memenuhi SLA produksi < 40 ms.
- **Auditor Rekonsiliasi Kas Harian (Robust MAD Z-Score) & Streamlit Operations Center:** Modul rekonsiliasi mengaudit berkas *batch* harian depo bus menggunakan skor deviasi absolut median ($|Z_{\text{MAD}}| > 3.5$), mencapai *Recall* 100% pada *batch* yang mengalami selisih kas $>$ Rp50.000 atau kehilangan paket transaksi $> 0.5\%$. Seluruh arsitektur divalidasi dengan pengujian otomatis `pytest` (DoD-1 s.d. DoD-4 lolos 100%) dan dipantau interaktif melalui Dashboard 4-Tab Streamlit.

Arsitektur Model (Evaluasi Data Uji Kronologis)	PR-AUC	F2-Score	Recall @ FPR ≤ 1%	Penghematan Biaya (Net)
1. Static Rule Engine Baseline	0.8461	0.8912	0.8991	Rp 11.446.000 (80,2%)
2. Isolation Forest (Unsupervised)	0.9559	0.9403	0.9495	Rp 13.292.500 (93,2%)
3. PyTorch Deep Autoencoder (DAE)	0.9692	0.9537	0.9716	Rp 13.466.000 (94,4%)
4. PyTorch Variational Autoencoder (VAE)	0.9648	0.9296	0.9621	Rp 13.135.500 (92,1%)
5. TransitSentinel Hybrid Stacking (VAE + IF + LGBM)	**0.9868**	**0.9811**	**0.9842**	**Rp 13.975.000 (98,0%)**

4. Bengawan Solo River Water Level Forecasting Pipeline

Pemodelan hidrologi spasial-temporal pada 30 stasiun pengamatan sungai menggunakan 187 fitur fisik dan ensemble 7 model

Proyek ini berfokus pada peramalan Tinggi Muka Air (TMA) sungai harian secara serentak di 30 stasiun pengamatan sepanjang Daerah Aliran Sungai (DAS) Bengawan Solo. Tantangan terberatnya adalah rentang prediksi pengujian yang mencapai 242 hari penuh ke depan (19 September 2025 hingga 18 Mei 2026, mencakup 21.780 baris prediksi) tanpa adanya data TMA aktual selama rentang pengujian tersebut. Artinya, kita tidak bisa mengandalkan nilai TMA hari kemarin (*autoregressive lag* pendek) karena nilainya tidak tersedia di masa depan; model harus benar-benar memahami hubungan fisik antara curah hujan, penguapan, cadangan air tanah, serta aliran air dari stasiun hulu ke hilir.

- **Pembersihan Data & Rekayasa 187 Fitur Hidrologi:** Dari 84.396 baris data latih (1 Januari 2023 s.d. 18 September 2025) dan 888.480 rekaman cuaca per jam, saya terlebih dahulu memperbaiki 100.080 rekaman radiasi matahari yang bernilai anomali (`-999`) serta mengisi 20.880 data cuaca kosong berdasarkan kedekatan lokasi stasiun. Selanjutnya, saya menyusun 187 fitur bebas kebocoran data yang meliputi: (1) defisit tekanan uap (*Vapor Pressure Deficit* / VPD) berdasarkan persamaan fisik FAO-56 Penman-Monteith, selisih curah hujan terhadap evapotranspirasi ($P - ET_0$), kelembapan tanah pada empat lapisan kedalaman (0–7 cm hingga 100–255 cm), dan indeks limpasan permukaan saat tanah jenuh; (2) statistik bergulir jangka panjang 720 jam (30 hari), 1440 jam (60 hari), dan 2160 jam (90 hari) untuk menangkap pola pelepasan air Waduk Gajah Mungkur di Wonogiri dan cadangan air tanah (*baseflow*); serta (3) bobot aliran hulu-hilir menggunakan jaringan sungai *HydroRIVERS v10* (`upstream_*`) yang digabungkan dengan interpolasi jarak terbalik (IDW) radius 35 km.
- **Ensemble 7 Model Huber & Penyesuaian Bias Awal (Cutoff Anchoring):** Saya menggabungkan 7 model berbeda yang dilatih dengan fungsi *Huber Loss* agar tahan terhadap lonjakan debit banjir ekstrem: dua model LightGBM (`lgbm_a`, `lgbm_b`), dua model XGBoost (`xgb_a`, `xgb_b`), dua model CatBoost (`cb_shallow`, `cb_base`), serta satu model regresi Ridge per stasiun (`station_ridge_expert`) yang menggunakan gelombang sinus-kosinus Fourier tahunan. Pada tahap akhir, prediksi dikoreksi menggunakan teknik *Causal Decaying-Residual Cutoff Anchoring*—yaitu menghitung median selisih prediksi pada 14 hari terakhir sebelum batas waktu pengujian, lalu meluruhkan nilai koreksi tersebut secara eksponensial (γ^h) sepanjang 242 hari ke depan.

Skema Validasi Waktu (4-Fold Rolling-Origin CV)	Baseline MAE (m)	Ensemble MAE (m)	Baseline RMSE (m)	Ensemble RMSE (m)
Fold 1 — Sep 2023 (Peralihan Kemarau ke Hujan)	0.8660	**0.6825**	2.7209	**2.6053**
Fold 2 — Mei 2024 (Peralihan Hujan ke Kemarau)	0.6573	**0.4199**	1.1612	**0.6607**
Fold 3 — Sep 2024 (Rentang Musim Identik Data Uji)	0.8924	**0.5581**	1.6372	**1.1676**
Fold 4 — Jan 2025 (Puncak Musim Penghujan)	0.7120	**0.4564**	1.4820	**1.1435**
Rata-rata 4-Fold (vs *baseline* v2 terdiversifikasi)	0.5840	**0.5360** (-8,2%)	1.4433	**1.3943** (-3,4%)

5. Pothole Image Segmentation Pipeline

Deteksi dan pemisahan area lubang jalan pada citra kamera kendaraan menggunakan gabungan UNet++, SegFormer, dan DeepLabV3+

Sistem ini dirancang untuk menandai area piksel jalan berlubang (*pothole*) secara presisi dari rekaman kamera jalan raya. Kesulitan utamanya adalah jumlah data latih awal yang terbatas (hanya 398 foto) dengan kondisi visual yang cukup menantang, seperti genangan air yang memantulkan cahaya, bayangan pepohonan yang gelap menyerupai lubang, serta ukuran lubang yang sangat bervariasi dari retakan kecil di kejauhan hingga lubang besar di depan kamera.

- **Augmentasi 5 Cabang di Memori & Gabungan 3 Arsitektur (5-Fold):** Untuk memperkaya variasi data tanpa merusak sudut pandang alami jalan raya, saya membuat pipeline augmentasi 5 cabang yang disimpan di RAM sehingga 398 citra dasar berkembang menjadi 1.990 sampel per epoch. Pembagian validasi dilakukan dengan 5-Fold *StratifiedGroupKFold* di atas tiga arsitektur yang saling melengkapi: **UNet++** (*backbone* `timm-efficientnet-b4` dengan atensi ruang-kanal `scSE` untuk ketajaman tepi objek), **SegFormer** (`nvidia/mit-b2` berbasis *vision transformer* untuk mengenali konteks permukaan jalan secara menyeluruh), dan **DeepLabV3+** (`se_resnext50_32x4d` dengan piramida konvolusi *atrous* untuk menangkap berbagai ukuran lubang).
- **Pelatihan Dua Tahap & Penyempurnaan Masker Histeresis:** Proses pelatihan dibagi menjadi dua tahap fungsi kerugian: tahap awal menggunakan gabungan `0.35 Focal + 0.45 Tversky + 0.20 Boundary BCE` agar pelatihan stabil, lalu dilanjutkan tahap penyempurnaan dengan `0.35 Lovasz-Hinge + 0.40 Tversky + 0.25 Boundary BCE` beserta *WarmupModelEMA* (*decay* 0.995) untuk mengoptimalkan skor irisan area (IoU/Dice) secara langsung. Pada saat pengujian, prediksi digabungkan melalui *Multi-Scale Test-Time Augmentation* (skala 0.75x, 1.0x, 1.25x dan pembalikan horizontal), disaring dengan ambang ganda histeresis (T_{high} dan T_{low}), penutupan celah morfologis (*morphological closing* & *hole filling*), lalu diubah ke format *Run-Length Encoding* (RLE) urutan kolom (Fortran).

Tahapan Konfigurasi Model Segmentasi	Resolusi Citra	Validation mIoU	Validation Dice
Baseline Model Tunggal (UNet ResNet-34, BCE + Dice Loss standar)	384×384	0.6215	0.7424
Single Fold UNet++ (`timm-efficientnet-b4` + `scSE` + Hybrid Loss)	512×512	0.6980	0.8045
5-Fold Ensemble (UNet++ + SegFormer + DeepLabV3+) + TTA + Hysteresis	**512×512**	**0.7336**	**0.8327**

6. Hierarchical Waste Classification with SigLIP

Klasifikasi sampah berjenjang coarse-to-fine (3 kategori utama & 8 sub-label terlatih) berbasis SigLIP-SO400M dan ensembel lintas keluarga model

Kebanyakan sistem pemilah sampah berbasis kamera hanya berhenti pada pemisahan kasar antara sampah organik dan anorganik, padahal fasilitas pengolahan membutuhkan pemilahan yang jauh lebih spesifik agar proses daur ulang tidak terkontaminasi limbah berbahaya. Pada proyek *AI_PilahYuk* ini, saya membersihkan gambar duplikat (deduplikasi MD5 + SHA256 + *perceptual dHash*, 1.174 duplikat dipindahkan) hingga menyisakan dataset bersih berjumlah **28.965 gambar** (manifest `v3clean`) yang dibagi secara proporsional (*stratified split* 70:15:15) menjadi **20.275 gambar latih**, **4.345 gambar validasi**, dan **4.345 gambar uji**. Sistem dirancang secara berjenjang (*coarse-to-fine*): 13 sub-label didefinisikan dalam taksonomi, lalu kelas minoritas digabung (*merge*) sehingga tersisa **8 sub-label yang dilatih dan dievaluasi** di bawah 3 kategori utama:

- **Taksonomi 13 Sub-Label (digabung menjadi 8 sub-label terlatih):** (1) **Organik — 2 sub-label terlatih:** `Sisa_Makanan` (diarahkan ke biokonversi larva *Black Soldier Fly / Maggot BSF*; `Sampah_Kebun` di-*merge* ke sini) dan `Limbah_Biologis` (biodigester metana); (2) **Recyclable / Anorganik — 3 sub-label terlatih:** `Plastik_Kemasan` (menyerap `Plastik_Campuran` & `Anorganik_Lainnya` via *merge*), `Tekstil`, dan `Kertas_Karton`; `Minyak_Jelantah` ditangani sebagai *rule-only* (esterifikasi biodiesel); (3) **B3 / Bahan Berbahaya & Beracun — 3 sub-label terlatih berisiko tinggi:** `Baterai` (ekstraksi logam berat hidrometalurgi), `Aerosol_Elektronik` (menyerap `B3_Rumah_Tangga`), dan `Medis_Farmasi` (insinerasi / *drug take-back*). Pelabelan sub-label dibangun lewat pipeline *hybrid*: label dari nama berkas (*gold*), *clustering* k-means per kategori, *zero-shot text tower* SigLIP terkalibrasi τ, *active learning* 3 putaran, serta pseudo-label LLM untuk train (agreement 100% vs manusia pada 4.380 gambar beririsan); set evaluasi val/test diverifikasi manusia (2.642 val, 2.610 test).
- **Backbone SigLIP-SO400M Beku, Embedding Mixup, & Ensembel Lintas Keluarga:** Setiap citra berukuran 384×384 piksel (*patch size* 14×14) diekstraksi menggunakan *frozen vision encoder* `google/siglip-so400m-patch14-384` menjadi vektor representasi 1.152 dimensi dengan strategi *embedding probe* dua tahap (ekstraksi sekali, lalu kepala klasifikasi ringan dilatih di atas vektor). Untuk mengatasi ketimpangan jumlah sampel antar kelas, kepala klasifikasi MLP (`Linear(1152 -> Hidden) -> GELU -> Dropout -> Linear`) dilatih menggunakan bobot kelas efektif $N/(C \times N_c)$, *Cross-Entropy Loss* dengan *label smoothing* 0.05, serta *Embedding Space Mixup* ($\alpha = 0.2$). Prediksi akhir diperkuat melalui ensembel lintas keluarga model (`ens_lintas_model`) yang menggabungkan **Multi-Seed Residual MLP, k-Nearest Neighbors (kNN, cosine), dan Support Vector Machine (SVM RBF)**.
- **Keputusan Metodologis Berbasis Audit (LoRA & Kalibrasi Bias Ditolak):** Dua jalur peningkatan diuji lalu sengaja ditolak karena tidak terbukti membantu di data validasi: (1) *fine-tuning* PEFT/LoRA ($r = 8$) pada 6 blok transformer teratas SigLIP justru menurunkan Macro-F1 (0.9883 vs 0.9956 embedding beku) karena *overfitting*, sehingga backbone tetap dibekukan; dan (2) kalibrasi bias per-kelas (P2) hanya memindahkan error *Recylable*↔*Organik* dan menurunkan skor uji, sehingga model final dipakai **tanpa** kalibrasi bias. Diagnostik

out-of-fold (*StratifiedGroupKFold*, *confident learning*, *near-duplicate* lintas split) dipakai untuk pembersihan label yang jujur, bukan untuk mengatrol metrik.

Strategi / Konfigurasi Model	Val Macro-F1	B3 Recall	B3 Precision	Karakteristik Evaluasi
`ens_seed_mlp2` (Multi-Seed Residual MLP, 5 seed)	0.9951	**0.9979**	0.9937	Performa kuat pada rata-rata Macro-F1 3 kelas utama
`ens_lintas_model` (Multi-Seed MLP + kNN + SVM)	**0.9956**	**0.9958**	**0.9979**	**Model Final Terpilih** (Test Macro-F1 0.9936; presisi B3 tinggi)
Sub-Head Hierarkis (`hier_oracle::mlp2`, 8 Sub-Label)	**0.9591**	0.9733	1.0000	Macro-F1 pada 2.011 sampel sub-label terverifikasi manusia
Sub-Head Hierarkis *end-to-end* (`hier_e2e::mlp2`)	0.9559	0.9733	1.0000	Realistis di produksi (routing kategori dari head 3-kelas)

7. The 15-Minute City Profiler — Urban Spatial Accessibility System

Evaluasi keterjangkauan fasilitas publik DKI Jakarta (SDG 11) dengan implementasi algoritma pengelompokan spasial murni menggunakan NumPy

Konsep *15-Minute City* (bagian dari target PBB *SDG 11: Sustainable Cities and Communities*) menilai apakah warga perkotaan dapat menjangkau kebutuhan hidup sehari-hari hanya dengan berjalan kaki atau bersepeda selama 15 menit (∼1 km). Dalam proyek ini, saya menarik titik fasilitas umum (*Point of Interest* / POI) di DKI Jakarta secara langsung dari basis data *OpenStreetMap* menggunakan pustaka `OSMnx`; setelah agregasi ke kisi analisis, terkumpul **18.782 fasilitas** yang terbagi ke dalam lima layanan pokok: Pendidikan (5.874 titik / 31,3%), Transportasi Publik (4.397 titik / 23,4%), Ruang Terbuka Hijau (4.185 titik / 22,3%), Kesehatan (2.452 titik / 13,1%), serta Pasar dan Ekonomi (1.874 titik / 10,0%).

- **Indeks Keberagaman Entropi Shannon & Perataan Spasial Tetangga:** Seluruh wilayah Jakarta dibagi ke dalam kisi berukuran 25×25 (625 sel membentang *bounding box* DKI Jakarta), dan hanya 57 sel yang memiliki fasilitas memadai serta berada di daratan aktif yang masuk ke tahap *clustering*. Agar wilayah yang hanya padat oleh satu jenis fasilitas (misalnya banyak halte tetapi tanpa fasilitas kesehatan) tidak mendapat nilai semu yang tinggi, saya menghitung indeks keberagaman *Normalized Shannon Entropy*: $H_{\text{norm}} = -\sum_{i=1}^{5} P_i \log(P_i) / \log(5) \in [0, 1]$. Selain itu, karena warga di perbatasan sel dapat berjalan kaki ke sel di sebelahnya, saya menerapkan perataan spasial 8 sel tetangga (*Neighbor-Weighted Spatial Smoothing* dengan bobot $\alpha = 0.4$): $X_{\text{smooth}}[i] = (1 - \alpha)X[i] + \alpha \cdot \text{mean}(X[\text{neighbors}_i])$.
- **Implementasi K-Means++ & Silhouette Score Murni dari Nol (Pure NumPy):** Tanpa menggunakan pustaka instan `scikit-learn`, saya menulis sendiri seluruh fungsi komputasi matriks di NumPy mulai dari pembakuan *Z-Score StandardScaler*, inisialisasi sentroid probabilistik **K-Means++** berbasis jarak kuadrat $D(x)^2$ (20 kali pengulangan inisialisasi / *multi-restart*), hingga pemilihan jumlah klaster terbaik otomatis lewat *WCSS Elbow* dan *Silhouette Score* (dilengkapi penjaga klaster tunggal). Konfigurasi optimal terpilih $\mathbf{K = 2}$ (*Silhouette Score* **0.4786**): **31 zona** tergolong "Kota 15 Menit" ideal (rata-rata 546,5 fasilitas/zona, indeks diversitas 0,922) dan **26 zona** "Pemukiman Standar" (rata-rata 70,8 fasilitas/zona, diversitas 0,473) yang sektor paling minimnya adalah fasilitas ekonomi/pasar. Hasil akhir dipetakan per kota administrasi dan disajikan sebagai peta interaktif `Folium`.

Kota Administrasi	Luas Total (km²)	Luas Ideal (km²)	% Cakupan 15-Min City	Sel Ideal / Total
Jakarta Selatan	142,31	142,31	**100,0%**	11 / 11
Jakarta Pusat	47,53	47,53	**100,0%**	6 / 6
Jakarta Timur	175,01	131,25	75,0%	11 / 14
Jakarta Barat	115,94	79,90	68,9%	9 / 12
Jakarta Utara	139,97	89,17	63,7%	9 / 15
Total DKI Jakarta	620,76	490,16	**79,0%**	**46 / 58**

8. DKI Jakarta Flood Risk Spatio-Temporal Data Engineering & PCA

Rekayasa integrasi tujuh sumber data hidrologi, kependudukan, dan citra satelit Sentinel-2 untuk pemetaan kerentanan banjir 267 kelurahan

Analisis risiko banjir di Jakarta sering kali terkendala oleh format data instansi yang terpisah-pisah dan tidak seragam. Dalam proyek ini, saya membangun alur pembersihan dan penggabungan tujuh dataset lintas domain berbeda resolusi (mulai dari pencatatan sensor 10 menitan hingga citra satelit resolusi 10 meter) menjadi satu profil risiko yang utuh untuk seluruh 267 kelurahan di DKI Jakarta sepanjang tahun 2018: (1) kejadian banjir BPBD, (2) Tinggi Muka Air Dinas SDA, (3) demografi Dukcapil, (4) prakiraan cuaca harian BMKG, (5) iklim bulanan BPS, (6) poligon batas administrasi BIG, dan (7) tutupan lahan Sentinel-2 (Google Dynamic World V1). Rekayasa data ini

menguraikan 135 baris banjir bulanan menjadi 238 kejadian kelurahan-hari pada 63 kelurahan terdampak, dengan total pengungsi puncak riil 13.827 jiwa (setelah koreksi penghitungan ganda).

- **Pemulihan Berkas Rusak, Regex Parser, & Citra Satelit Google Earth Engine:** (1) Pada data Tinggi Muka Air (TMA) Dinas SDA yang berjumlah 876.447 baris, saya menemukan bahwa 12 berkas bulanan berekstensi `.xls` tersebut sebenarnya berisi kode tabel HTML mentah; saya mengekstraksinya menggunakan `BeautifulSoup` dan `lxml`, membuang 2.231 baris dengan penanda waktu rusak (`0000-00-00`), serta mempertahankan nilai elevasi negatif yang sah secara fisik pada pompa polder pesisir (seperti Pintu Air Pluit `-1.777 mm` dan Pompa Cideng `-150 mm` di bawah permukaan laut); (2) Pada laporan banjir BPBD, saya membuat *parser* ekspresi reguler (*regex*) untuk menerjemahkan catatan teks tinggi genangan (seperti `"10 s/d 25 cm"`) menjadi nilai rata-rata numerik (rerata $44,36 \pm 36,60$ cm, tertinggi 200 cm); (3) Melalui **Google Earth Engine**, saya mengekstraksi citra satelit *Sentinel-2 Dynamic World V1* resolusi 10 meter guna memperoleh proporsi tutupan beton/bangunan (`built`), pepohonan (`trees`), dan badan air (`water`) di tiap kelurahan; serta (4) Menggabungkan data curah hujan BMKG Kemayoran ($1.459,8$ mm/tahun, puncak Februari $431,2$ mm) dan menyederhanakan kolom jumlah penduduk pria/wanita Dukcapil yang berkorelasi sangat tinggi ($r = 0.98$) menjadi kepadatan penduduk per km^2.
- **Pemetaan Kuadran Risiko dengan Principal Component Analysis (PCA):** Setelah standardisasi *Z-Score* pada 9 prediktor kontinu (tanpa *data leakage* dari variabel target BPBD), tiga komponen utama memenuhi kriteria Kaiser-Guttman ($\lambda > 1,0$) dan merangkum **73,65% variansi kumulatif**; bidang 2D PC_1–PC_2 saja merangkum **61,02%** dan dipakai untuk pemetaan biplot empat kuadran tipologi wilayah:

Sumbu Komponen Utama	Varians	Bobot Variabel Dominan	Makna Fisik & Wilayah Terdampak
PC1 — Tekanan Urban & Ancaman Sungai	**$\lambda = 3,60$ (39,82%)**	Area Terbangun, Kepadatan Penduduk, Jam Siaga Pintu Air	Menggambarkan padatnya bangunan beton dan luapan sungai; Kuadran I (urban padat Selatan & Timur) menjadi episentrum banjir utama (**162 hari banjir**, rata-rata 1,27 hari/kelurahan, **13.511 pengungsi puncak** = 97,7% total).
PC2 — Daya Serap & Retensi Alami	**$\lambda = 1,92$ (21,20%)**	Tutupan Pohon GEE, Jarak ke Pintu Air, Maksimum TMA	Mengukur kemampuan resapan tanah; memisahkan kawasan hijau di Jakarta Selatan dari cekungan padat dan area polder Jakarta Utara.
PC3 — Komponen Residual (Kaiser-Guttman)	**$\lambda = 1,14$ (12,63%)**	Varians tersisa di atas ambang $\lambda > 1,0$	Melengkapi 73,65% variansi kumulatif tiga komponen utama.

---

9. Face Anti-Spoofing Detection Pipeline

Deteksi pemalsuan wajah biometrik 6 kelas berbasis analisis spektrum frekuensi 2D FFT, ConvNeXt, dan Grad-CAM

Sistem ini dirancang untuk mengamankan proses verifikasi wajah (*face recognition e-KYC*) dari berbagai upaya pemalsuan identitas. Alih-alih sekadar menebak asli atau palsu secara biner, model dilatih untuk mengenali enam kategori secara spesifik: wajah asli (`realperson`), rekaman layar gawai/monitor (`fake_screen`), foto hasil cetakan kertas (`fake_printed`), topeng tiga dimensi (`fake_mask`), patung manekin (`fake_mannequin`), serta serangan manipulasi tak dikenal (`fake_unknown`).

- **Pembersihan Duplikat MD5 & Analisis Frekuensi 2D Fast Fourier Transform (FFT):** Sebelum membagi lipatan validasi, seluruh citra dipindai menggunakan *hash* kriptografis MD5 untuk membuang berkas gambar kembar yang dapat memicu kebocoran data. Karena foto yang ditampilkan lewat layar monitor maupun kertas cetak selalu meninggalkan pola kisi mikroskopis (pola *Moiré* dan titik *halftone* printer), saya mengubah citra ke domain frekuensi menggunakan **2D FFT** (`fftshift`) dan mengekstraksi profil energi spektrum azimutal 1D untuk membantu jaringan membedakan tekstur kulit asli dari pantulan buatan.
- **Pelatihan 5-Fold ConvNeXt & Penjelasan Visual Grad-CAM:** Model utama menggunakan arsitektur **ConvNeXt** yang dilatih dalam skema 5-Fold dengan teknik *frozen-stage warmup* (membekukan lapisan awal di epoch pertama agar bobot kepala klasifikasi stabil sebelum melatih seluruh jaringan), fungsi *Multi-Class Focal Loss*, dan penalaan *hyperparameter* otomatis via Optuna. Di tahap akhir, saya menambahkan visualisasi **Grad-CAM** untuk menampilkan peta panas bagian wajah atau tepi pantulan layar yang menjadi dasar keputusan model.

---

10. NaviGreen — Hybrid-Cloud Eco-Routing & Telematics Platform

Arsitektur aplikasi navigasi rendah emisi dan pemantauan gaya mengemudi berbasis telematika sensor inersia serta kontur elevasi jalan

NaviGreen merupakan rancangan platform aplikasi bergerak berarsitektur *hybrid-cloud* yang bertujuan menekan pemborosan bahan bakar minyak (BBM) dan emisi karbon kendaraan di jalan perkotaan. Jika aplikasi peta biasa

hanya mencari jalur tercepat atau terpendek, NaviGreen menggabungkan kondisi topografi jalan dan perilaku pengemudi secara langsung ke dalam perhitungan konsumsi energi:

- **Deteksi Gaya Mengemudi Agresif di Perangkat Tepi (Edge Inertial Telematics):** Aplikasi membaca sensor gerak ponsel (*accelerometer*, *gyroscope*) dan GPS selama perjalanan untuk mengenali pengereman mendadak (*harsh braking*), akselerasi kejut, serta kecepatan berlebih di tikungan yang terbukti meningkatkan konsumsi BBM sebesar 15–30%.
- **Perhitungan Kontur Kemiringan Jalan & Integrasi Transportasi Publik (GTFS):** Di sisi server awan, mesin pencari rute memanggil **Google Elevation API** untuk menghitung beban tanjakan jalan (*road grade penalty*) sehingga pengemudi diarahkan ke jalur yang lebih landai dan hemat bahan bakar. Selain itu, sistem mengolah data jadwal **General Transit Feed Specification (GTFS)** untuk menyarankan opsi perjalanan kombinasi transportasi umum (*Park-and-Ride*) yang dilengkapi sistem poin insentif pengurangan karbon.